Chapitre 3

Les stratégies d'ordonnancement des processus

Sommaire

Introduction (1)

- Le SE gère plusieurs processus
- L'efficacité théorique serait maximale si le nombre de processeurs était comparable à celui des processus
- Souvent une machine possède un seul processeur
- En multiprogrammation, on a plusieurs processus encours d'exécution
- Problème: plusieurs processus se partagent un seul processeur
- Solution: définir une politique d'accès au processeur

Introduction (2)

- L'ordonnancement définit des critères selon lesquels les processus ont accès au processeur.
  - Exemples:
    - Un carrefour routier
    - Guichets d'une administration
- Critère d'ordonnancement
  - Optimiser l'utilisation de l'UCT
  - Besoins et priorités des applications

Introduction (3)

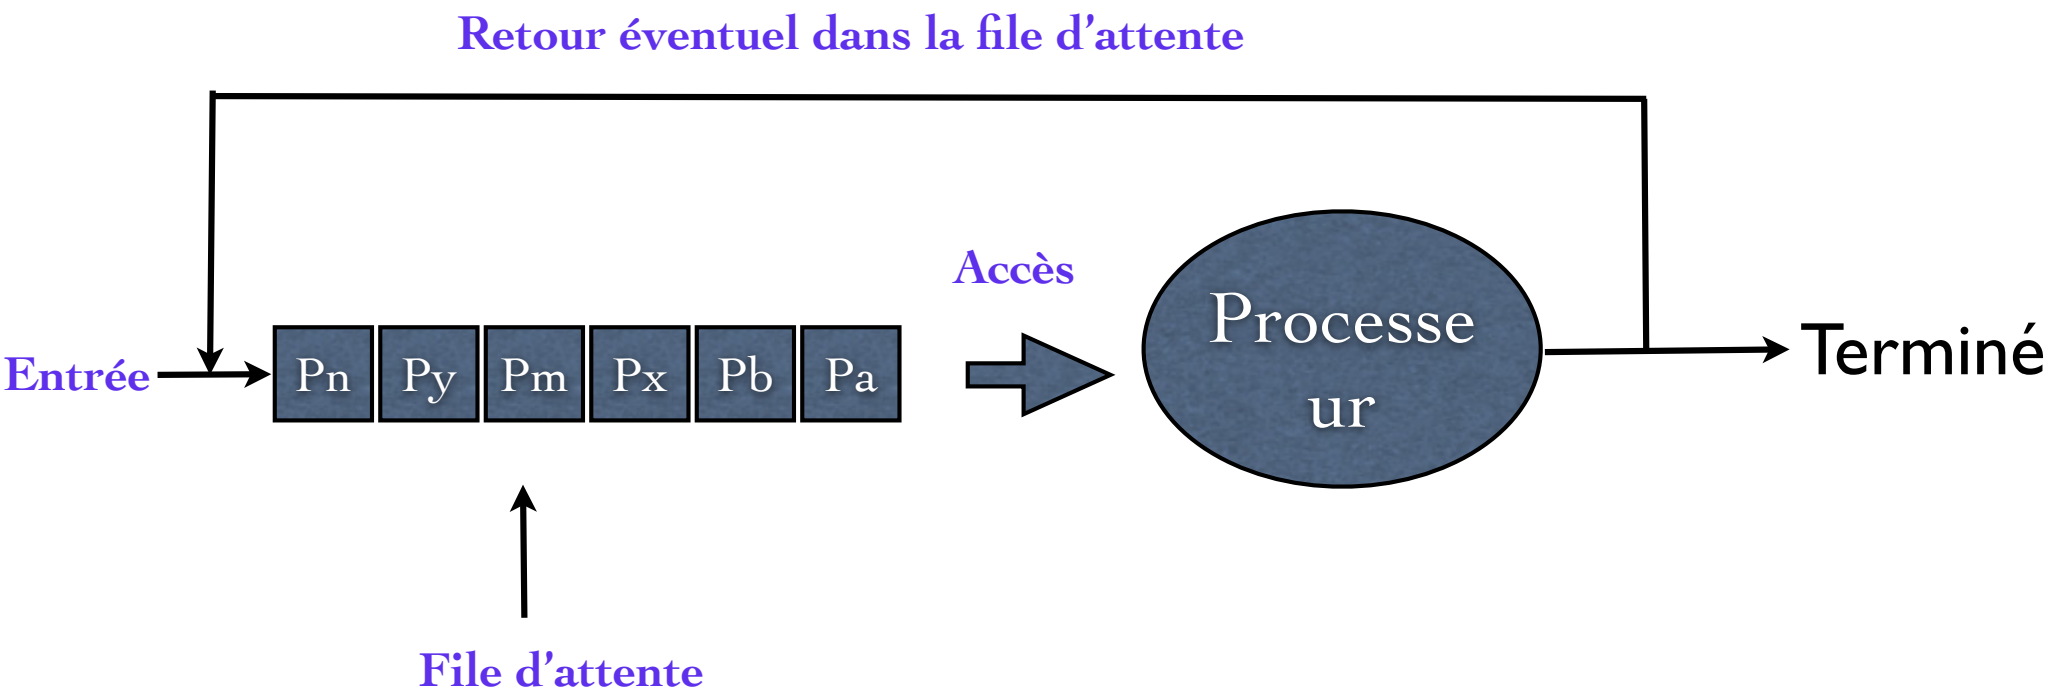

- Schéma d'ordonnancement

Optimisation des ressources

- Maximiser le pourcentage d'utilisation du processeur
- Maximiser le débit (nombre de processus exécutés/unités de temps)
- Minimiser le temps de rotation: temps de terminaison - temps d'arrivée (attente incluses)
- Minimiser le temps d'attente (temps passé dans la file d'attente)
- Minimiser le temps de réponse (pour les système interactif): temps entre une demande et première réponse

Priorité des utilisateurs

- **Ordre d'arrivée**:le premier arrivé est le premier servi (caisses au RestoU, au supermarché, à la poste etc.)
- **Urgence :** le premier servi est celui dont le besoin d'accès rapide à la ressource est le plus grand (pompier)
- **Importance :** le premier servi est celui dont l'accès à la ressource est le plus important (personne âgée dans les transports en commun)

Pénalisation

- La pénalité d'un processus est liée à son temps d'attente, c'est le nombre d'unités de temps durant lesquelles le processus est présent dans la file d'attente (sans être exécuté)
- Mesurer de la pénalité (retard T) en fonction du temps d'attente et du temps d'exécution.
  - $T = \frac{e}{e + a}$
    - e = temps d'exécution processus
    - e+a= temps d'exécution+ temps d'attente
  - Dans le cas idéal T=1=e/e, donc a=0

Types d'ordonnancement

- **Ordonnancement non préemptif** (sans réquisition): le processus à l'état élu est traité jusqu'à sa fin quelque soit sa durée. L'importance, l'urgence etc. ne sont pas prise en compte

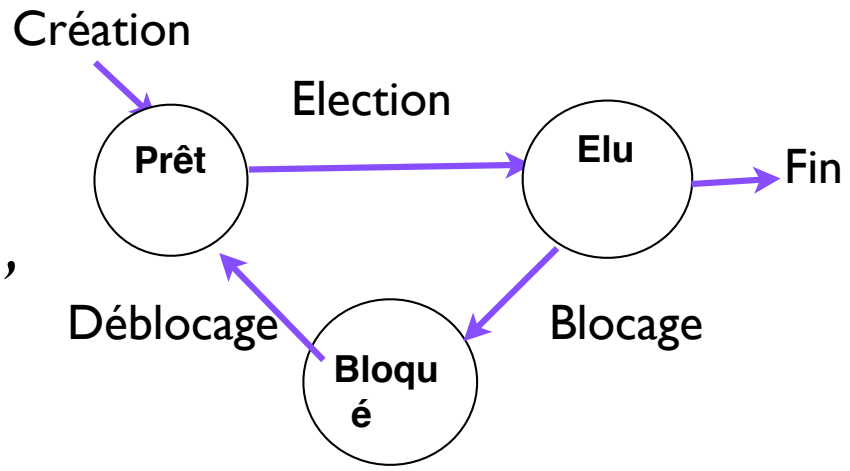

- **Ordonnancement préemptif** (avec réquisition): en fonction des critères d'ordonnancement, le SE remet le processus en file d'attente avant la fin de son exécution

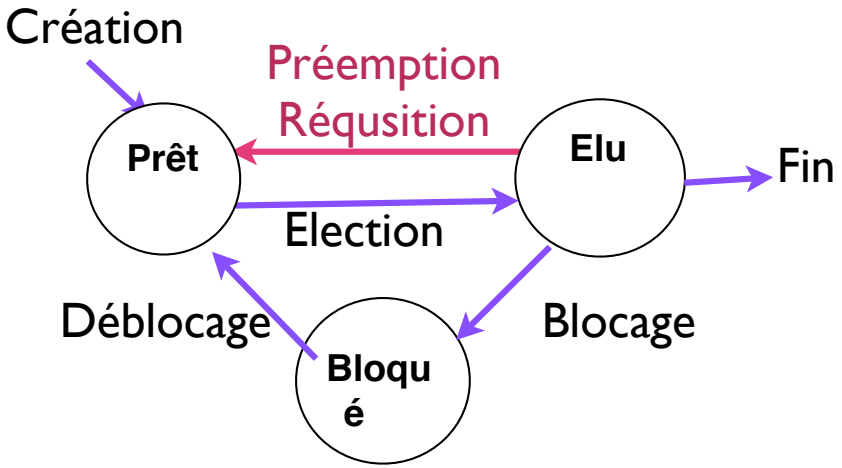

FIFO (First In, First Out)

- Le traitement est séquentiel
- Premier arrivé en file d'attente, premier servi
- Les processus courts sont pénalisés
  - Exemple: photocopieuse utilisée par
    - Une personne qui photocopie un livre
    - Une personne qui photocopie une page

FIFO (First In, First Out)

- Exemple 1

Processus	P1	P2	P3
Durée d'exécution	24	3	3

- Si les processus arrivent au temps 0 dans l'ordre: P_1, P_2, P_3
  - Le schéma d'exécution

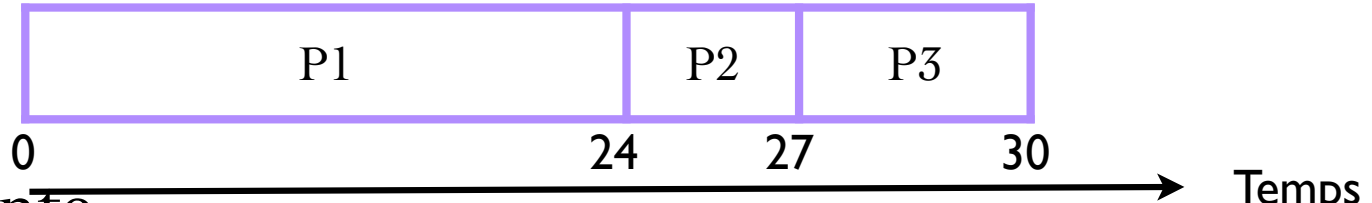

  - Le schéma d'attente

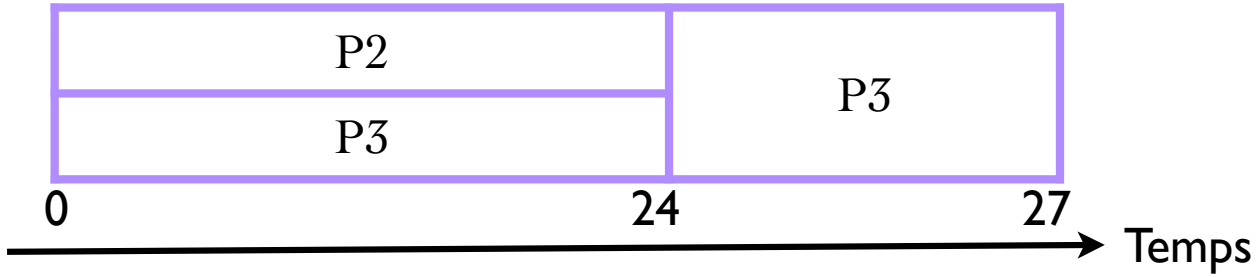

  - Temps d'attente pour P1= 0; P2= 24; P3= 27
  - Temps attente moyen: (0 + 24 + 27)/3 = 17

FIFO (First In, First Out)

- Exemple 2

Processus	P1	P2	P3
Durée d'exécution	24	3	3

- Si les processus arrivent au temps 0 dans l'ordre: P_2, P_3, P_1
  - Le schéma d'exécution

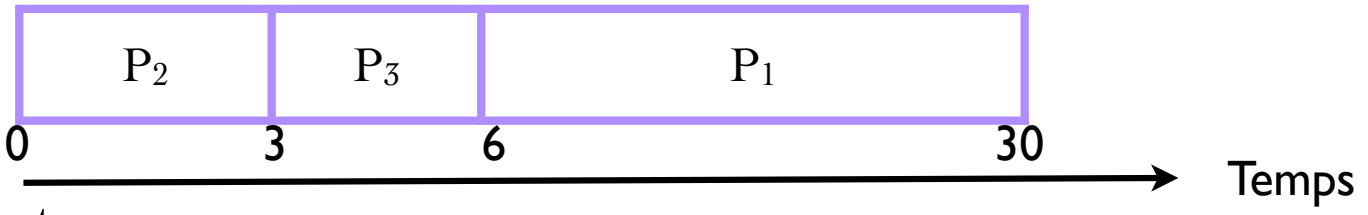

  - Le schéma d'attente

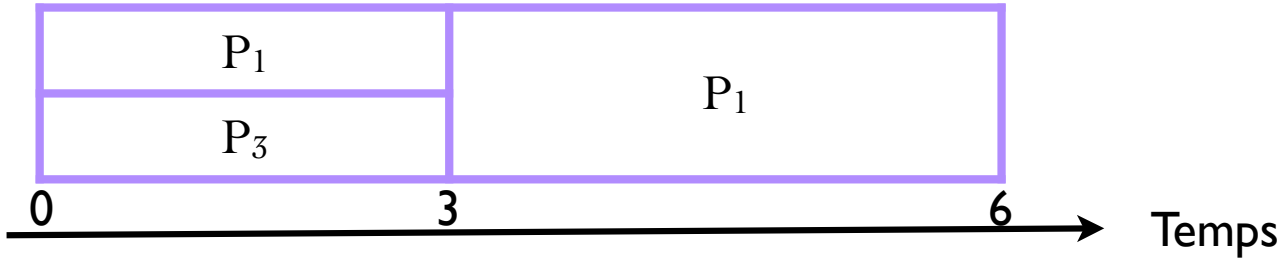

    - Temps d'attente pour $P_1 = 6$ $P_2 = 0$ $P_3 = 3$
    - Temps moyen d'attente: $(6 + 0 + 3)/3 = 3$

Temps d'attente est fonction de l'ordre d'arrivée

SJF (Shortest Job First)

- **Shortest JOB First**: Plus court travail
- Il s'agit d'une évolution de la stratégie précédente
- La file d'attente est ordonnée non plus de façon chronologique mais en fonction du temps d'exécution nécessaire (on fait passer en tête les travaux courts)
- Un processus qui arrive est classé dans la file d'attente en fonction de sa durée
- Les travaux longs sont pénalisés, au pire ils risquent de ne jamais être exécutés tant que de petits travaux sont soumis au système
- En cas d'égalité de temps d'exécution, on applique FIFO

SRTF (Shortest Remaining-Time First)

- Favorise le temps restant le plus court
- Si un processus qui dure moins que le restant du processus courant se présente plus tard, l'UCT est enlevée au processus courant et donnée à ce nouveau processus
- Favorise les travaux courts

Algorithmes préemptifs: Tourniquet ou Round Robin(1)

- Le SE attribue à chaque processus un temps (quantum de temps) pendant lequel il est autorisé à s'exécuter
- l'UCT est enlevée au processus courant P_x si le quantum s'achève avant la fin du processus et est donnée au premier processus P_y de la file d'attente
- Le processus P_x se trouve ainsi en queue de liste
- La gestion de la file d'attente est faite selon FIFO :
- Les travaux assez courts sont vite servis
- Le tourniquet garanti que les travaux longs sortiront du système au bout d'un temps fini

Algorithmes préemptifs: Tourniquet ou Round Robin (2)

- L'efficacité du système dépend de la valeur du quantum
  - Si le changement de contexte s'opère en c ms
  - Et le quantum fixé à q ms
  - La surcharge introduite par le système est: $\frac{c}{c+q}$
    - Un quantum trop petit provoque trop de changement de contexte et augmente la surcharge, ralentit la machine
    - Trop long, la réactivité du système diminue, les petits travaux sont pénalisés

Priorité

- Affectation d'une priorité à chaque processus (p.ex. un nombre entier)
- souvent les petits chiffres dénotent des hautes priorités
- Exemple: 0 la plus haute
- L'UCT est donnée au processus prêt avec la plus haute priorité **avec** ou **sans** préemption
- A priorité égale, on applique FIFO

Priorité

- Problèmes possibles:
  - Famine: les processus moins prioritaires n'arrivent jamais à exécuter
- Solution d'ajustement dynamique de la priorité
  - Modifier la priorité d'un processus en fonction de son âge et de son historique d'exécution
    - Augmenter la priorité d'un processus pénalisé
    - Diminuer la priorité d'un processus en fonction du temps passé dans le CPU